

Examen de Aprendizaje Automático
ETSINF, Universitat Politècnica de València, 28 de enero de 2015

Apellidos: Nombre: Grupo:

Cuestiones (2 puntos; tiempo estimado: 30 minutos)

Marca cada recuadro con una única opción de entre las dadas. Cada acierto suma 1/2 puntos y cada fallo resta 1/6 puntos.

- 1 ☐ C Se ha evaluado un sistema de Aprendizaje Automático mediante la técnica de *validación cruzada en B bloques* (“B-fold Cross Validation”) con $B = 100$ y utilizando un conjunto de datos de entrenamiento que contiene 1000 muestras. Se han obtenido un total de 22 errores. Indicar cuál de las afirmaciones siguientes es razonable:

- A) La talla de entrenamiento efectiva es 990 muestras y el error estimado es $2.2\% \pm 0.1\%$
- B) La talla de entrenamiento efectiva es de 900 muestras y el error estimado es 2.2%
- C) La talla de test efectiva es de 1000 muestras y el error estimado es $2.2\% \pm 0.7\%$
- D) El error estimado es $22\% \pm 7\%$.

- 2 ☐ A Considerar la siguiente modificación de la función de Widrow y Hoff

$$q_S(\boldsymbol{\theta}) = \sum_{n=1}^N (\boldsymbol{\theta}^t \mathbf{x}_n - y_n) + \lambda \boldsymbol{\theta}^t \sum_{n=1}^N \mathbf{x}_n,$$

Al aplicar la técnica de descenso por gradiente, en la iteración k el vector de pesos, $\boldsymbol{\theta}$, se modifica como: $\boldsymbol{\theta}(k+1) = \boldsymbol{\theta}(k) - \rho_k \nabla q_S(\boldsymbol{\theta})|_{\boldsymbol{\theta}=\boldsymbol{\theta}(k)}$. En esta expresión, el gradiente, $\nabla q_S(\boldsymbol{\theta})|_{\boldsymbol{\theta}=\boldsymbol{\theta}(k)}$, es:

- A) $(1 + \lambda) \sum_{n=1}^N \mathbf{x}_n$
- B) $\sum_{n=1}^N \mathbf{x}_n + \lambda \boldsymbol{\theta}(k)$
- C) $\sum_{n=1}^N \mathbf{x}_n + \lambda$
- D) $\sum_{n=1}^N \boldsymbol{\theta}(k)^t \mathbf{x}_n + \lambda$

- 3 ☐ A Considerar el aprendizaje mediante máquinas de vectores soportes y márgenes blandos con una muestra de aprendizaje $\mathbf{x}_1, \dots, \mathbf{x}_N$ no separable linealmente. Si un multiplicador de Lagrange óptimo α_j^* , asociado a la restricción $c_j (\boldsymbol{\theta}^t \mathbf{x}_{dj} n + \theta_0) \geq 1 - \zeta_j$, $1 \leq j \leq N$, es cero, entonces:

- A) La muestra \mathbf{x}_j está clasificada correctamente.
- B) La muestra \mathbf{x}_j está mal clasificada.
- C) La muestra \mathbf{x}_j está clasificada correctamente pero $\boldsymbol{\theta}$ y θ_0 no es canónico con respecto a la muestra.
- D) La muestra \mathbf{x}_j es un vector soporte.

- 4 ☐ A La distribución de probabilidad conjunta en una red bayesiana de tres nodos A, B y C es $P(A, B, C) = P(C) P(A | C) P(B | C)$. Marcar cuál es la afirmación correcta:

- A) $P(A, B | C) = P(A | C) P(B | C)$
- B) En general, $P(A, B | C) \neq P(A | C) P(B | C)$
- C) $P(A, B | C) = P(C | A) P(C | B)$
- D) $P(A, B | C) = P(A) P(B)$

Problema 1 (3 puntos; tiempo estimado: 30 minutos)

En la siguiente tabla se presenta una muestra de entrenamiento no linealmente separable en \mathbb{R}^2 y los correspondientes multiplicadores de Lagrange óptimos obtenidos al entrenar una máquina de vectores soporte con esta muestra (y $C=10$):

i	1	2	3	4	5	6	7	8
x_{i1}	1	3	2	4	3	2	4	4
x_{i2}	4	1	3	2	4	5	4	3
Clase	+1	+1	+1	+1	-1	-1	+1	-1
α_i^*	3.38	0	0	5.75	9.13	0	10	10

- Obtener la función discriminante lineal correspondiente
- Representar gráficamente la frontera lineal de separación entre clases y las muestras de entrenamiento, indicando cuáles son vectores soporte.
- Clasificar la muestra $(1, 1)^t$.

a) Pesos de la función discriminante:

$$\theta^* = c_1 \alpha_1^* \mathbf{x}_1 + c_4 \alpha_4^* \mathbf{x}_4 + c_5 \alpha_5^* \mathbf{x}_5 + c_7 \alpha_7^* \mathbf{x}_7 + c_8 \alpha_8^* \mathbf{x}_8$$

$$\theta_1^* = (+1)(1)(3.38) + (+1)(4)(5.75) + (-1)(3)(9.13) + (+1)(4)(10) + (-1)(4)(10) \approx -1.0$$

$$\theta_2^* = (+1)(4)(3.38) + (+1)(2)(5.75) + (-1)(4)(9.13) + (+1)(4)(10) + (-1)(3)(10) = -1.5$$

Usando el vector soporte \mathbf{x}_4 (que verifica la condición: $0 < \alpha_4^* < C$)


$$\theta_0^* = c_4 - \theta^{*t} \mathbf{x}_4 = 1 - ((-1.0)(4) + (-1.5)(2)) = 8.0$$

b) Frontera de separación y representación gráfica:

Ecuación de la frontera lineal de separación: $8.0 - 1.0 x_1 - 1.5 x_2 = 0 \rightarrow x_2 \approx -0.67 x_1 + 5.3$.

Los vectores de entrenamiento son todos los de la tabla. De ellos, los vectores soporte son: $(1, 4)^t, (4, 2)^t, (3, 4)^t, (4, 4)^t, (4, 3)^t$.

Representación gráfica:




c) Clasificación de la muestra $(1, 1)^t$:

El valor de la función discriminante para este vector es: $\theta_0^* + \theta_1^* 1 + \theta_2^* 1 = 5.5 > 0 \Rightarrow$ clase +1.

Problema 2 (3 puntos; tiempo estimado: 30 minutos)

El perceptrón multicapa de la figura se utiliza para resolver un problema de regresión, con función de activación de los nodos de la capa de salida y de la capa oculta de tipo sigmoid, y factor de aprendizaje $\rho = 1.0$.



Dado un vector de entrada $x = 1$ y su valor deseado de salida $t = -1$, Calcular:

- las salidas de todas las unidades
- los correspondientes errores en el nodo de la capa de salida y en los dos nodos de la capa oculta.
- Los nuevos valores de los pesos de las conexiones θ_{21}^1 , que va del nodo 1 de entrada al nodo 2 de la capa oculta, y θ_{12}^2 , que va del nodo 2 de la capa oculta al nodo de la capa de salida.

a) Las salidas de todas las unidades

$$\begin{aligned}\phi_1^1 &= \theta_{11}^1 x_1 + \theta_{10}^1 = -0.5; & s_1^1 &= \frac{1}{1+\exp(-\phi_1^1)} = 0.378 \\ \phi_2^1 &= \theta_{21}^1 x_1 + \theta_{20}^1 = 0.5; & s_2^1 &= \frac{1}{1+\exp(-\phi_2^1)} = 0.622 \\ \phi_1^2 &= \theta_{11}^2 s_1^1 + \theta_{12}^2 s_2^1 + \theta_{10}^2 = 0.878; & s_1^2 &= \frac{1}{1+\exp(-\phi_1^2)} = 0.706\end{aligned}$$

a) El error en la capa de salida es: $\delta_1^2 = (t_1 - s_1^2) s_1^2 (1 - s_1^2) = -0.354$

Los errores en la capa de oculta son: $\delta_1^1 = \delta_1^2 \theta_{11}^2 s_1^1 (1 - s_1^1) = -0.042$; $\delta_2^1 = \delta_1^2 \theta_{12}^2 s_2^1 (1 - s_2^1) = 0.042$

b) El nuevo peso θ_{12}^2 es: $\theta_{12}^2 = \theta_{12}^2 + \rho \delta_1^2 s_2^1 = (-0.5) + (1) (-0.354) (0.622) = -0.720$

El nuevo peso θ_{21}^1 es: $\theta_{21}^1 = \theta_{21}^1 + \rho \delta_2^1 x_1 = (+1.0) + (1) (0.042) (1.0) = 1.042$

Problema 3 (2 puntos; tiempo estimado: 20 minutos)


Considerar la red bayesiana \mathcal{R} definida como $P(R, X, Y, Z) = P(R) P(X | R) P(Y | R) P(Z | R)$, cuya variable R toma valores en $\{1, 2, 3\}$ y las variables X, Y, Z , en el conjunto $\{\text{"a"}, \text{"b"}, \text{"c"}\}$. Las distribuciones de probabilidad asociadas son como sigue:

- $P(R)$ es uniforme: $P(R = 1) = P(R = 2) = P(R = 3)$
- $P(X | R)$, $P(Y | R)$ y $P(Z | R)$ son idénticas y vienen dadas en la tabla T.

T	"a"	"b"	"c"
1	1/3	0	2/3
2	1/4	1/2	1/4
3	0	3/5	2/5

- Representar gráficamente la red
- Obtener una expresión simplificada de $P(X, Y, Z | R)$ en función de las distribuciones que definen \mathcal{R} y calcular $P(X = \text{"a"}, Y = \text{"a"}, Z = \text{"a"} | R = 1)$
- Calcular $P(R = 3 | X = \text{"b"}, Y = \text{"b"}, Z = \text{"b"})$

a) Representación gráfica de la red:



b) Expresión simplificada de $P(X, Y, Z | R)$:

$$P(X, Y, Z | R) = \frac{P(R, X, Y, Z)}{P(R)} = P(X | R) P(Y | R) P(Z | R)$$

$$P(X = \text{"a"}, Y = \text{"a"}, Z = \text{"a"} | R = 1) = \frac{1}{3} \cdot \frac{1}{3} \cdot \frac{1}{3} = \frac{1}{27}$$

$$c) \quad P(R = 3 | X = \text{"b"}, Y = \text{"b"}, Z = \text{"b"}) = \frac{P(R = 3, X = \text{"b"}, Y = \text{"b"}, Z = \text{"b"})}{P(X = \text{"b"}, Y = \text{"b"}, Z = \text{"b"})}$$

$$= \frac{P(R = 3) P(X = \text{"b"} | R = 3) P(Y = \text{"b"} | R = 3) P(Z = \text{"b"} | R = 3)}{\sum_{r \in \{1, 2, 3\}} P(R = r) P(X = \text{"b"} | R = r) P(Y = \text{"b"} | R = r) P(Z = \text{"b"} | R = r)}$$

$$= \frac{\frac{1}{3} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5}}{\frac{1}{3} \cdot 0 \cdot 0 \cdot 0 + \frac{1}{3} \cdot \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{3} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5}} = \frac{216}{341} \approx 0.633$$