

Examen de Aprendizaje Automático
ETSINF, Universitat Politècnica de València, 11 de enero de 2016

Apellidos: Nombre: Grupo:

Cuestiones (2 puntos; tiempo estimado: 30 minutos)

Marca cada recuadro con una única opción de entre las dadas. Cada acierto suma $1/2$ puntos y cada fallo resta $1/6$ puntos.

- 1 ☐ **D** Se ha evaluado un sistema de Aprendizaje Automático mediante la técnica de *Exclusión individual* (“Leaving One Out”) y utilizando un conjunto de datos que contiene 200 muestras. Se han obtenido un total de 10 errores. Indicar cuál de las afirmaciones siguientes es razonable:

- A) La talla de entrenamiento efectiva es 190 muestras, la del test es de 10 muestras y el error estimado es $5.0\% \pm 0.3\%$
- B) La talla de entrenamiento efectiva es de 199 muestras, la del test es de 1 muestra y el error estimado es $5.0 \pm 3.0\%$
- C) La talla de entrenamiento efectiva es de 200 muestras, la del test es de 10 muestras y el error estimado es $5.0 \pm 0.3\%$
- D) La talla de entrenamiento efectiva es de 199 muestras, la del test es de 200 muestras y el error estimado es $5.0 \pm 3.0\%$

- 2 ☐ **D** En el problema de optimización con restricciones

$$\begin{array}{ll} \text{minimizar} & q(\Theta), \quad \Theta \in \mathbb{R}^D \\ \text{sujecto a} & v_i(\Theta) \leq 0, \quad 1 \leq i \leq k \end{array}$$


se cumplen las condiciones complementarias de Karush-Kuhn-Tucker $\alpha_i^* v_i(\Theta^*) = 0$ para $1 \leq i \leq k$. Indicar cuál de las siguientes afirmaciones se deduce de ellas:

- A) Si para un i , $\alpha_i^* = 0$, entonces $v_i(\Theta^*) > 0$
- B) Si para un i , $\alpha_i^* = 0$, entonces $v_i(\Theta^*) = 0$,
- C) Si para un i , $v_i(\Theta^*) = 0$, entonces $\alpha_i^* = 0$
- D) Si para un i , $\alpha_i^* > 0$, entonces $v_i(\Theta^*) = 0$

- 3 ☐ **C** En la estimación por máxima verosimilitud de los parámetros de una mezcla de K gaussianas de matriz de covarianza común y conocida a partir de N vectores de entrenamiento, los parámetros a estimar son: el vector-media μ_k y el peso π_k de cada gaussiana, $k, 1 \leq k \leq K$. Identificar cuál de las siguientes afirmaciones es *correcta*:

- A) Se puede usar *descenso por gradiente*, ya que los valores de μ_k no están sujetos a ninguna restricción, lo que hace innecesario recurrir a la técnica de los *multiplicadores de Lagrange*.
- B) La solución se obtiene en un paso, utilizando directamente la *optimización lagrangiana* de la verosimilitud de los N vectores de entrenamiento. En este caso, hay un único multiplicador de Lagrange, β , asociado a la restricción de igualdad: $\sum_{k=1}^K \pi_k = 1$.
- C) El método más adecuado es el de *esperanza-maximización* (EM), el cual garantiza que se cumple la restricción $\sum_{k=1}^K \pi_k = 1$. Esto es así gracias a que, en cada iteración de EM, los valores de $\pi_k, 1 \leq k \leq K$, se obtienen como medias de valores de variables latentes, usando una expresión que se deriva analíticamente mediante la técnica de los *multiplicadores de Lagrange* con la restricción indicada.
- D) El método más adecuado sería el de *esperanza-maximización* (EM), pero no es posible utilizarlo ya que EM es un método iterativo que no garantiza el cumplimiento de la restricción de igualdad: $\sum_{k=1}^K \pi_k = 1$.

- 4 ☐ **B** En la red bayesiana lineal



¿cuál de las relaciones siguientes es falsa en general?

- A) $P(x_1, x_4 | x_2) = P(x_1 | x_2) P(x_4 | x_2)$
- B) $P(x_1, x_4 | x_2) = P(x_1) P(x_4)$
- C) $P(x_1, x_4 | x_2) = P(x_1 | x_2) P(x_4 | x_1, x_2)$
- D) $P(x_1, x_4 | x_2) = P(x_4 | x_2) P(x_1 | x_4, x_2)$

Problema 1 (3 puntos; tiempo estimado: 30 minutos)

En la siguiente tabla se presenta una muestra de entrenamiento no linealmente separable y los correspondientes multiplicadores de Lagrange óptimos obtenidos al entrenar una máquina de vectores soporte con esta muestra (y $C=10$):

i	1	2	3	4	5
x_{i1}	1	1	1	1	1
x_{i2}	1	2	3	4	5
Clase	+1	+1	-1	+1	-1
α_i^*	0	3.56	10	10	3.56

- Obtener la función discriminante lineal correspondiente
- Representar gráficamente la frontera lineal de separación entre clases y las muestras de entrenamiento, indicando cuáles son vectores soporte.
- Clasificar la muestra $(1, 4.5)^t$.

- Pesos de la función discriminante:

$$\theta^* = c_2 \alpha_1^* \mathbf{x}_2 + c_3 \alpha_4^* \mathbf{x}_3 + c_4 \alpha_5^* \mathbf{x}_4 + c_5 \alpha_7^* \mathbf{x}_5$$

$$\theta_1^* = 0.0$$

$$\theta_2^* \approx -0.67$$

Usando el vector soporte \mathbf{x}_5 (que verifica la condición : $0 < \alpha_5^* < C$)

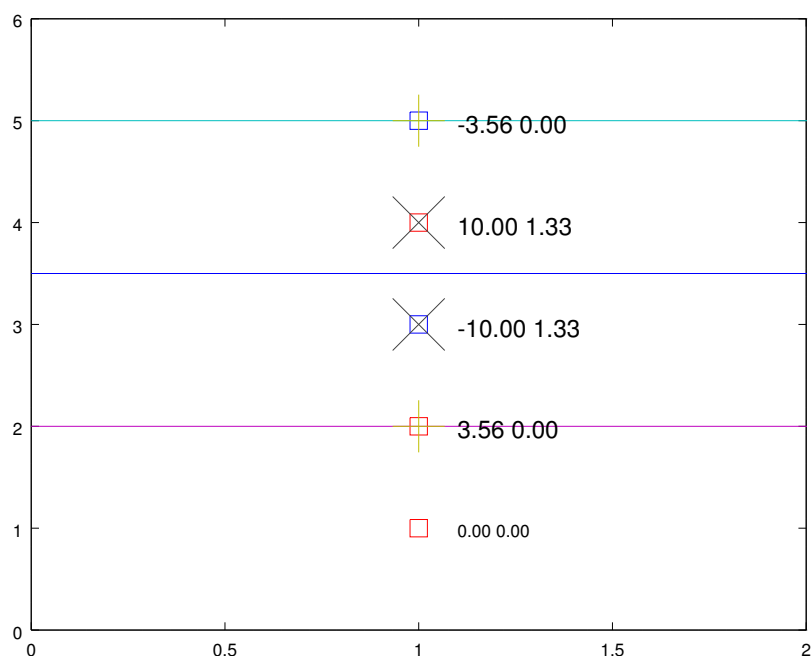
$$\theta_0^* = c_5 - \theta^{*t} \mathbf{x}_5 \approx 2.33$$

- Frontera de separación y representación gráfica:

Ecuación de la frontera lineal de separación: $2.33 - 0.67 x_2 = 0$

Los vectores de entrenamiento son todos los de la tabla. De ellos, los vectores soporte son: $(1, 2)^t, (1, 3)^t, (1, 4)^t, (1, 5)^t$.

Representación gráfica:




- Clasificación de la muestra $(1, 4.5)^t$:

El valor de la función discriminante para este vector es: $2.33 - 0.67 x_2 \approx -0.67 < 0 \Rightarrow$ clase -1.

Problema 2 (3 puntos; tiempo estimado: 30 minutos)

El perceptrón multicapa de la figura se utiliza para resolver un problema de regresión, con función de activación de los nodos de la capa de salida y de la capa oculta de tipo *tangente hiperbólica*, y factor de aprendizaje $\rho = 0.5$.



Dado un vector de entrada $x = 1$ y su valor deseado de salida $t = +1$, Calcular:

- las salidas de todas las unidades
- los correspondientes errores en el nodo de la capa de salida y en los dos nodos de la capa oculta.
- Los nuevos valores de los pesos de las conexiones θ_{21}^1 , que va del nodo 1 de entrada al nodo 2 de la capa oculta, y θ_{12}^2 , que va del nodo 2 de la capa oculta al nodo de la capa de salida.

a) Las salidas de todas las unidades

$$\begin{aligned}\phi_1^1 &= \theta_{11}^1 x_1 + \theta_{10}^1 = 0.0; & s_1^1 &= \frac{\exp(\phi_1^1) - \exp(-\phi_1^1)}{\exp(\phi_1^1) + \exp(-\phi_1^1)} = 0.0 \\ \phi_2^1 &= \theta_{21}^1 x_1 + \theta_{20}^1 = 0.0; & s_2^1 &= \frac{\exp(\phi_2^1) - \exp(-\phi_2^1)}{\exp(\phi_2^1) + \exp(-\phi_2^1)} = 0.0 \\ \phi_1^2 &= \theta_{11}^2 s_1^1 + \theta_{12}^2 s_2^1 + \theta_{10}^2 = 1.0; & s_1^2 &= \frac{\exp(\phi_1^2) - \exp(-\phi_1^2)}{\exp(\phi_1^2) + \exp(-\phi_1^2)} = 0.76159\end{aligned}$$

b) El error en la capa de salida es:

$$\delta_1^2 = (t_1 - s_1^2) (1 - (s_1^2)^2) = +0.10012$$

Los errores en la capa de oculta son:

$$\delta_1^1 = \delta_1^2 \theta_{12}^2 (1 - (s_1^1)^2) = -0.10012; \quad \delta_2^1 = \delta_1^2 \theta_{22}^2 (1 - (s_2^1)^2) = +0.10012$$

c) El nuevo peso θ_{12}^2 es: $\theta_{12}^2 = \theta_{12}^2 + \rho \delta_1^2 s_2^1 = (+1.0) + (0.5) (+0.10012) (0.0) = 1.0$

El nuevo peso θ_{21}^1 es: $\theta_{21}^1 = \theta_{21}^1 + \rho \delta_2^1 x_1 = (+1.0) + (0.5) (+0.10012) (1.0) = 1.0501$

Problema 3 (2 puntos; tiempo estimado: 20 minutos)


Considerar la red bayesiana \mathcal{R} definida como $P(R, X, Y, Z) = P(R) P(X | R) P(Y | R) P(Z | R)$, cuya variable R toma valores en $\{1, 2, 3\}$ y las variables X, Y, Z , en el conjunto $\{\text{"a"}, \text{"b"}, \text{"c"}\}$. Las distribuciones de probabilidad asociadas son como sigue:

- $P(R)$ es uniforme: $P(R = 1) = P(R = 2) = P(R = 3)$
- $P(X | R)$, $P(Y | R)$ y $P(Z | R)$ son idénticas y vienen dadas en la tabla T.

T	"a"	"b"	"c"
1	1/3	0	2/3
2	1/4	1/2	1/4
3	0	3/5	2/5

- Representar gráficamente la red
- Obtener una expresión simplificada de $P(X, Y, Z | R)$ en función de las distribuciones que definen \mathcal{R} y calcular $P(X = \text{"a"}, Y = \text{"a"}, Z = \text{"a"} | R = 1)$
- Calcular $P(R = 3 | X = \text{"b"}, Y = \text{"b"}, Z = \text{"b"})$

a) Representación gráfica de la red:



b) Expresión simplificada de $P(X, Y, Z | R)$:

$$P(X, Y, Z | R) = \frac{P(R, X, Y, Z)}{P(R)} = P(X | R) P(Y | R) P(Z | R)$$

$$P(X = \text{"a"}, Y = \text{"a"}, Z = \text{"a"} | R = 1) = \frac{1}{3} \cdot \frac{1}{3} \cdot \frac{1}{3} = \frac{1}{27}$$

$$c) \quad P(R = 3 | X = \text{"b"}, Y = \text{"b"}, Z = \text{"b"}) = \frac{P(R = 3, X = \text{"b"}, Y = \text{"b"}, Z = \text{"b"})}{P(X = \text{"b"}, Y = \text{"b"}, Z = \text{"b"})}$$

$$= \frac{P(R = 3) P(X = \text{"b"} | R = 3) P(Y = \text{"b"} | R = 3) P(Z = \text{"b"} | R = 3)}{\sum_{r \in \{1, 2, 3\}} P(R = r) P(X = \text{"b"} | R = r) P(Y = \text{"b"} | R = r) P(Z = \text{"b"} | R = r)}$$

$$= \frac{\frac{1}{3} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5}}{\frac{1}{3} \cdot 0 \cdot 0 \cdot 0 + \frac{1}{3} \cdot \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{3} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{3}{5}} \approx 0.633$$