

Examen de Aprendizaje Automático  
ETSINF, Universitat Politècnica de València, 27 de enero de 2016

Apellidos:

Nombre:

Grupo:

**Cuestiones (2 puntos; tiempo estimado: 30 minutos)**

Marca cada recuadro con una única opción de entre las dadas. Cada acierto suma 1/2 puntos y cada fallo resta 1/6 puntos.

- 1 ☐ A Identifica cuál de las siguientes afirmaciones es *errónea o impropia*:
- A) La *teoría de la decisión estadística* es idónea para problemas de *clasificación*, pero es inadecuada para problemas de *regresión* en aprendizaje de funciones.
  - B) *Clasificación* puede considerarse como un caso particular de *regresión* y los problemas de *sobreajuste* y *sobregeneralización* le afectan de forma similar
  - C) En el *aprendizaje activo* se asume que un agente externo al sistema se encarga de etiquetar datos de entrenamiento seleccionados por el sistema
  - D) El *aprendizaje adaptativo* es esencialmente un modo *supervisado* de aprendizaje
- 2 ☐ A Se ha evaluado un sistema de Aprendizaje Automático mediante un proceso de *validación cruzada en B bloques* ("B-fold Cross Validation") con  $B = 8$  y 1000 muestras etiquetadas. En este proceso se han producido 15 errores en total. Indicar cuál de las afirmaciones siguientes es razonable:
- A) La talla de entrenamiento efectiva es 875 muestras y el error estimado es  $1.5\% \pm 0.75\%$
  - B) La talla de entrenamiento efectiva es de 992 muestras y el error estimado es inferior al 2%
  - C) La talla de test efectiva es de 125 muestras y el error estimado es  $12\% \pm 5.7\%$ .
  - D) Como en cada bloque de test solo hay 125 muestras, el error es muy variable, pudiéndose estimar como  $1.5\% \pm 5.7\%$ .
- 3 ☐ A Se desea ajustar por mínimos cuadrados la función  $f: \mathbb{R}^2 \rightarrow R$ , definida como:  $y = f(\mathbf{x}) \stackrel{\text{def}}{=} ax_1^2 + bx_2^2 + cx_1x_2$  a una secuencia de  $N$  pares entrada-salida:  $S = (\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)$ . La técnica empleada es minimizar por descenso por gradiente la función de error cuadrático:

$$q(a, b, c) = \sum_{n=1}^N (f(\mathbf{x}_n) - y_n)^2$$

Identifica la afirmación acertada de entre las siguientes:

- A) El vector gradiente es:  $2 \sum_{n=1}^N (f(\mathbf{x}_n) - y_n) \cdot (x_{n1}^2, x_{n2}^2, x_{n1}x_{n2})^t$
  - B) El gradiente es  $2ax_1 + 2bx_2 + cx_1x_2$
  - C) El descenso por gradiente solo es aplicable a funciones convexas, pero  $q(\cdot)$  no lo es.
  - D) La técnica de descenso por gradiente no es aplicable en este caso ya que la función a ajustar,  $f(\cdot)$ , no es lineal.
- 4 ☐ A Considerar el aprendizaje mediante máquinas de vectores soportes y márgenes blandos con una muestra de aprendizaje  $\mathbf{x}_1, \dots, \mathbf{x}_N$  no separable linealmente. Si un multiplicador de Lagrange óptimo  $\alpha_j^*$ , asociado a la restricción  $c_j (\boldsymbol{\theta}^t \mathbf{x}_{djn} + \theta_0) \geq 1 - \zeta_j$ ,  $1 \leq j \leq N$ , es cero, entonces:
- A) La muestra  $\mathbf{x}_j$  está clasificada correctamente.
  - B) La muestra  $\mathbf{x}_j$  está mal clasificada.
  - C) La muestra  $\mathbf{x}_j$  está clasificada correctamente pero  $\boldsymbol{\theta}$  y  $\theta_0$  no es canónico con respecto a la muestra.
  - D) La muestra  $\mathbf{x}_j$  es un vector soporte.



## Problema 1 (3 puntos; tiempo estimado: 30 minutos)

En la siguiente tabla se presenta una muestra de entrenamiento no linealmente separable en  $\mathbb{R}^2$  y los correspondientes multiplicadores de Lagrange óptimos obtenidos al entrenar una máquina de vectores soporte con esta muestra (y  $C=10$ ):

$i$	1	2	3	4	5	6
$x_{i1}$	4	1	2	3	4	2
$x_{i2}$	1	2	2	2	2	3
Clase	-1	+1	-1	+1	-1	+1
$\alpha_i^*$	0	3.11	10.00	10.00	3.78	0.67

- Obtener la función discriminante lineal correspondiente
- Representar gráficamente la frontera lineal de separación entre clases y las muestras de entrenamiento, indicando cuáles son vectores soporte.
- Clasificar la muestra  $(1,1)^t$ .

a) Pesos de la función discriminante:

$$\theta^* = c_2 \alpha_2^* \mathbf{x}_2 + c_3 \alpha_3^* \mathbf{x}_3 + c_4 \alpha_4^* \mathbf{x}_4 + c_5 \alpha_5^* \mathbf{x}_5 + c_6 \alpha_6^* \mathbf{x}_6$$

$$\theta_1^* = (+1) (3.11) (1) + (-1) (10) (2) + (+1) (10) (3) + (-1) (3.78) (4) + (+1) (0.67) (2) \approx -0.67$$

$$\theta_2^* = (+1) (3.11) (2) + (-1) (10) (2) + (+1) (10) (2) + (-1) (3.78) (2) + (+1) (0.67) (3) \approx +0.67$$

Usando el vector soporte  $\mathbf{x}_5$  (que verifica la condición :  $0 < \alpha_5^* < C = 10$ )


$$\theta_0^* = c_5 - \theta^{*t} \mathbf{x}_5 = -1 - ((-0.67) (4) + (0.67) (2)) = 0.34$$

b) Frontera de separación y representación gráfica:

$$\text{Ecuación de la frontera lineal de separación: } -0.67 x_1 + 0.67 x_2 + 0.34 = 0$$

Los vectores de entrenamiento son todos los de la tabla. De ellos, los vectores soporte son:  $(1, 2)^t, (2, 2)^t, (3, 2)^t, (4, 2)^t, (2, 3)^t$ .

Representación gráfica:




c) Clasificación de la muestra  $(1, 1)^t$ :

El valor de la función discriminante para este vector es:  $\theta_0^* + \theta_1^* 1 + \theta_2^* 1 = +0.34 > 0 \Rightarrow$  clase +1.



## Problema 2 (3 puntos; tiempo estimado: 30 minutos)

El perceptrón multicapa de la figura se utiliza para resolver un problema de regresión, con función de activación de los nodos de la capa de salida y de la capa oculta de tipo *sigmoide*, y factor de aprendizaje  $\rho = 1.0$ .



Dado un vector de entrada  $\mathbf{x}^t = (1, -1)$ , las salidas de las unidades de la capa de salida son  $s_1^2 = 0.740$  y  $s_2^2 = 0.722$  y las de las unidades ocultas son  $s_1^1 = 0.731$ ,  $s_2^1 = 0.731$  y  $s_3^1 = 0.047$ . Si el valor deseado de salida es  $\mathbf{t}^t = (1, 0)$ , calcular:

- Los correspondientes errores en los nodos de la capa de salida y en los nodos de la capa oculta.
- Los nuevos valores de los pesos de las conexiones  $\theta_{32}^1$  y  $\theta_{13}^2$ .

- Los errores en la capa de salida son:

$$\delta_1^2 = (t_1 - s_1^2) s_1^2 (1 - s_1^2) = +0.050;$$

$$\delta_2^2 = (t_2 - s_2^2) s_2^2 (1 - s_2^2) = -0.145$$

Los errores en la capa de oculta son:

$$\delta_1^1 = (\delta_1^2 \theta_{11}^2 + \delta_2^2 \theta_{21}^2) s_1^1 (1 - s_1^1) = +0.038;$$

$$\delta_2^1 = (\delta_1^2 \theta_{12}^2 + \delta_2^2 \theta_{22}^2) s_2^1 (1 - s_2^1) = -0.038;$$

$$\delta_3^1 = (\delta_1^2 \theta_{13}^2 + \delta_2^2 \theta_{23}^2) s_3^1 (1 - s_3^1) = +0.009$$

- El nuevo peso  $\theta_{13}^2$  es:  $\theta_{13}^2 = \theta_{13}^2 + \rho \delta_1^2 s_3^1 = (+1.0) + (1) (0.050) (0.047) = 1.002;$

$$\text{El nuevo peso } \theta_{32}^1 \text{ es: } \theta_{32}^1 = \theta_{32}^1 + \rho \delta_3^1 x_2 = (+1.0) + (1) (0.009) (-1.0) = 0.991$$




### Problema 3 (2 puntos; tiempo estimado: 20 minutos)

Las variables aleatorias  $A, B, C, D$  toman valores en el conjunto  $\{0, 1\}$ . La distribución de probabilidad conjunta de estas variables viene dada por  $P(A, B, C, D) = P(A) P(B) P(C | A, B) P(D | B)$ , donde las distribuciones de probabilidad asociadas son:

$$\begin{aligned} P(A = 1) &= 0.3 & P(A = 0) &= 0.7 \\ P(B = 1) &= 0.4 & P(B = 0) &= 0.6 \\ P(C = 1 | A = 0, B = 0) &= 0.1 & P(C = 0 | A = 0, B = 0) &= 0.9 \\ P(C = 1 | A = 0, B = 1) &= 0.2 & P(C = 0 | A = 0, B = 1) &= 0.8 \\ P(C = 1 | A = 1, B = 0) &= 0.3 & P(C = 0 | A = 1, B = 0) &= 0.7 \\ P(C = 1 | A = 1, B = 1) &= 0.4 & P(C = 0 | A = 1, B = 1) &= 0.6 \\ P(D = 1 | B = 0) &= 0.3 & P(D = 0 | B = 0) &= 0.7 \\ P(D = 1 | B = 1) &= 0.7 & P(D = 0 | B = 1) &= 0.3 \end{aligned}$$

Y cuya representación gráfica es



- Calcular la probabilidad conjunta para  $A = 1, B = 1, C = 1$  y  $D = 1$ .
- Obtener una expresión simplificada de  $P(A | B, C, D)$  y calcular su valor para  $A = 1$  cuando  $B = 1, C = 1$  y  $D = 1$ .
- Dados  $B = 1, C = 1$  y  $D = 1$ , ¿Cuál es el mejor valor de  $A$  que se puede predecir?

- Calcular la probabilidad conjunta para  $A = 1, B = 1, C = 1$  y  $D = 1$ .

$$P(A = 1, B = 1, C = 1, D = 1) = P(A = 1) P(B = 1) P(C | A = 1, B = 1) P(D | B = 1) = 0.3 \cdot 0.4 \cdot 0.4 \cdot 0.7 = 0.0336$$

- Obtener una expresión simplificada de  $P(A | B, C, D)$  y calcular su valor para  $A = 1$  cuando  $B = 1, C = 1$  y  $D = 1$ .

$$\begin{aligned} P(A | B, C, D) &= \frac{P(A, B, C, D)}{P(B, C, D)} = \frac{P(A) P(B) P(C | A, B) P(D | B)}{P(B) P(D | B) \sum_a P(A = a) P(C | A = a, B)} \\ &= \frac{P(A) P(C | A, B)}{P(A = 0) P(C | A = 0, B) + P(A = 1) P(C | A = 1, B)} \end{aligned}$$

$$P(A = 1 | B = 1, C = 1, D = 1) = \frac{0.3 \cdot 0.4}{0.7 \cdot 0.2 + 0.3 \cdot 0.4} = 0.4615$$

- Dados  $B = 1, C = 1$  y  $D = 1$ , ¿Cuál es el mejor valor de  $A$  que se puede predecir?

$$a^* = \arg \max_{a \in \{0, 1\}} P(A = a | B = 1, C = 1, D = 1)$$

$$P(A = 0 | B = 1, C = 1, D = 1) = 1 - 0.4615 = 0.5385 \geq 0.4615 \Rightarrow \text{valor óptimo es } A = 0$$