

Examen de Aprendizaje Automático
ETSINF, Universitat Politècnica de València, 25 de enero de 2017

Apellidos: Nombre: Grupo:

Cuestiones (2 puntos; tiempo estimado: 30 minutos)

Marca cada recuadro con una única opción de entre las dadas. Cada acierto suma 1/2 puntos y cada fallo resta 1/6 puntos.

- 1 ☐ Sea S un conjunto de 1000 datos supervisados o etiquetados. En el diseño de un sistema de reconocimiento de formas se utiliza el método de *validación cruzada en 10 bloques* y se obtienen los errores siguientes: (2,4,2,3,0,7,4,4,1). Indicar cual de las siguientes afirmaciones es incorrecta.

- A) El error estimado es $p_e = 3.1\%$
- B) El intervalo de confianza al 95 % es ± 0.9
- C) El test efectivo es de 100 muestras
- D) El tamaño de entrenamiento efectivo es de 900 muestras

- 2 ☐ En el problema de aprendizaje de modelos probabilísticos con variables observables \mathbf{x}_n y latentes \mathbf{z}_n

$$L_S(\Theta) = \sum_{n=1}^N \log \left(\sum_{\mathbf{z}_n} P(\mathbf{x}_n, \mathbf{z}_n | \Theta) \right)$$


se utiliza la técnica esperanza-maximización (EM). Indicar cuál de las siguientes afirmaciones es cierta:

- A) En cada iteración, el paso E consiste en obtener una estimación de todas las variables \mathbf{x}_n y \mathbf{z}_n , y el paso M, obtener los parámetros óptimos de Θ utilizando la estimación de las variables \mathbf{x}_n y \mathbf{z}_n obtenidas en el paso E.
- B) En cada iteración, el paso E consiste en obtener los valores de las variables latentes \mathbf{z}_n que maximizan la función objetivo $L_S(\Theta)$, y el paso M, obtener los parámetros óptimos de Θ utilizando la estimación de las variables \mathbf{z}_n obtenidas en el paso E.
- C) En cada iteración, el paso E consiste en obtener los valores de todas las variables \mathbf{x}_n y \mathbf{z}_n que maximizan la función $L_S(\Theta)$, y el paso M, obtener los parámetros óptimos de Θ utilizando la estimación de las variables \mathbf{x}_n y \mathbf{z}_n obtenidas en el paso E.
- D) En cada iteración, el paso E consiste en obtener una estimación de las variables latentes \mathbf{z}_n , y el paso M, obtener los parámetros óptimos de Θ utilizando la estimación de las variables \mathbf{z}_n obtenidas en el paso E.

- 3 ☐ Considerar el aprendizaje mediante máquinas de vectores soportes y márgenes blandos con una muestra de aprendizaje $\mathbf{x}_1, \dots, \mathbf{x}_N$ no separable linealmente. Si un multiplicador de Lagrange óptimo α_j^* , asociado a la restricción $c_j (\theta^t \mathbf{x}_j + \theta_0) \geq 1 - \zeta_j$, $1 \leq j \leq N$, es cero, entonces la muestra \mathbf{x}_j está bien clasificada pero ¿cuál de las siguientes afirmaciones es falsa?:

- A) $\zeta_j = 0$
- B) Se produce un error de margen
- C) No hay error de margen
- D) La muestra \mathbf{x}_j no es un vector soporte

- 4 ☐ En la red bayesiana



¿cuál de las relaciones siguientes es verdadera?

- A) $P(a, b) = P(a) P(b)$
- B) $P(a, d) = P(a) P(d)$
- C) $P(a, b | d) = P(a | d) P(b | d)$
- D) $P(a, c | b) = P(a | b) P(c | b)$

Problema 1 (3 puntos; tiempo estimado: 30 minutos)

La siguiente tabla contiene una muestra de entrenamiento linealmente separable en \mathbb{R}^2 y los correspondientes multiplicadores de Lagrange óptimos obtenidos al entrenar una máquina de vectores soporte con esta muestra:

i	1	2	3	4	5	6	7
x_{i1}	1	1	2	1	4	3	6
x_{i2}	6	3	3	1	5	4	2
Clase	+1	+1	+1	+1	-1	-1	-1
α_i^*	0.25	0	1.0	0	0	1.25	0

- Obtener la función discriminante lineal correspondiente
- Calcular el margen óptimo
- Obtener la ecuación de la frontera de separación entre clases y representarla gráficamente, junto con los datos de entrenamiento.
- Clasificar la muestra $(2, 6)^t$.

a) Función discriminante lineal (FDL):

- Vector de pesos:

$$\theta_1^* = +1 \cdot 0.25 \cdot 1 + 1 \cdot 1.0 \cdot 2 - 1 \cdot 1.25 \cdot 3 = -1.5$$

$$\theta_2^* = +1 \cdot 0.25 \cdot 6 + 1 \cdot 1.0 \cdot 3 - 1 \cdot 1.25 \cdot 4 = -0.5$$

- Peso umbral (con el primer vector de entrenamiento): $\theta_0^* = (+1) - (-1.5 \cdot 1 - 0.5 \cdot 6) = 5.5$

- FDL: $\phi(\mathbf{x}) = -1.5 x_1 - 0.5 x_2 + 5.5$

c) Margen óptimo:

$$\frac{2}{\|\theta^*\|} = \frac{2}{\sqrt{(-1.5)^2 + (-0.5)^2}} = 1.265$$


Alternativamente:

$$2 \left(\sum_{n \in \mathcal{V}} \alpha_n^* \right)^{-1/2} = \frac{2}{\sqrt{0.25 + 1.0 + 1.25}} = 1.265$$

b) Ecuación de la frontera de decisión:

$$-1.5 x_1 - 0.5 x_2 + 5.5 = 0 \Rightarrow x_2 = -3x_1 + 11$$


Representación gráfica:



- Clasificación de la muestra $(2, 6)$: $\phi(2, 6) = -1.5 \cdot 2 - 0.5 \cdot 6 + 5.5 = -0.5 < 0 \Rightarrow \text{clase} = -1$

Problema 2 (3 puntos; tiempo estimado: 30 minutos)

La red hacia adelante (“feedforward”) de la figura se utiliza para resolver un problema de regresión, con función de activación de los nodos de la capa de salida y de la capa oculta de tipo *tangente hiperbólica*, y factor de aprendizaje $\rho = 1.0$.



Dados unos pesos iniciales $\theta_{10}^{10} = \theta_{11}^{10} = \theta_{12}^{20} = \theta_{10}^{21} = \theta_{11}^{21} = 1.0$, un vector de entrada $\mathbf{x}^t = (1, 1)$ y su valor deseado de salida $t = +1$, Calcular:

- las salidas de todas las unidades
- los correspondientes errores en el nodo de la capa de salida y en el de la capa oculta.
- Los nuevos valores de los pesos de las conexiones

- Las salidas de todas las unidades

$$\phi_1^1 = \theta_{10}^{10} + \theta_{11}^{10} x_1 = 2.0$$

$$s_1^1 = \frac{\exp(\phi_1^1) - \exp(-\phi_1^1)}{\exp(\phi_1^1) + \exp(-\phi_1^1)} = 0.96402$$

$$\phi_1^2 = \theta_{10}^{21} + \theta_{12}^{20} x_2 + \theta_{11}^{21} s_1^1 = 2.96402$$

$$s_1^2 = \frac{\exp(\phi_1^2) - \exp(-\phi_1^2)}{\exp(\phi_1^2) + \exp(-\phi_1^2)} = 0.99469$$

- El error en la capa de salida es:

$$\delta_1^2 = (t_1 - s_1^2) (1 - (s_1^2)^2) = 0.0000562$$

El error en la capa de oculta es:

$$\delta_1^1 = (\delta_1^2 \theta_{11}^{21}) (1 - (s_1^1)^2) = 0.000004$$

- Los nuevos pesos son:

$$\theta_{10}^{21} = \theta_{10}^{21} + \rho \delta_1^2 (+1) = 1.0 + 1.0 * 0.0000562 * 1.0 = 1.0000562$$

$$\theta_{11}^{21} = \theta_{11}^{21} + \rho \delta_1^2 s_1^1 = 1.0 + 1.0 * 0.0000562 * 0.96402 = 1.0000542$$

$$\theta_{12}^{20} = \theta_{12}^{20} + \rho \delta_1^2 x_2 = 1.0 + 1.0 * 0.0000562 * 1.0 = 1.0000562$$

$$\theta_{10}^{10} = \theta_{10}^{10} + \rho \delta_1^1 (+1) = 1.0 + 1.0 * 0.000004 * 1.0 = 1.0000040$$

$$\theta_{11}^{10} = \theta_{11}^{10} + \rho \delta_1^1 x_1 = 1.0 + 1.0 * 0.000004 * 1.0 = 1.0000040$$

Problema 3 (2 puntos; tiempo estimado: 20 minutos)


Considerar la red bayesiana \mathcal{R} definida como $P(W, X, Y, Z) = P(X) P(Y | X) P(Z | X) P(W | Y, Z)$, cuyas variables aleatorias, W, X, Y, Z , toman valores en el conjunto $\{a, b\}$. Las distribuciones de probabilidad asociadas son como sigue:

- $P(X)$ es uniforme: $P(X = a) = P(X = b)$,
- $P(W | Y, Z)$, $P(Y | X)$ y $P(Z | X)$ vienen dadas en las siguientes tablas:

$P(w y, z)$		$w:$		$y:$		$P(y x)$		$P(z x)$	
$Y:$	$Z:$	a	b	a	b	a	b	a	b
a	a	1/2	1/2	1/3	2/3	1/3	2/3	1/3	2/3
a	b	1/4	3/4	1/4	3/4	1/4	3/4	1/4	3/4
b	a	1/5	4/5						
b	b	3/5	2/5						

- Representar gráficamente la red
- Obtener una expresión simplificada de $P(W, Y, Z | X)$ en función de las distribuciones que definen \mathcal{R} y calcular $P(W = b, Y = b, Z = b | X = b)$
- Obtener una expresión simplificada de $P(X | W, Y, Z)$, y calcular $P(X = b | W = b, Y = b, Z = b)$

a) Representación gráfica de la red:



b) Expresión simplificada de $P(W, Y, Z | X)$:

$$\begin{aligned}
 P(W, Y, Z | X) &= \frac{P(W, X, Y, Z)}{P(X)} = \frac{\cancel{P(X)} P(Y | X) P(Z | X) P(W | Y, Z)}{\cancel{P(X)}} \\
 &= P(Y | X) P(Z | X) P(W | Y, Z)
 \end{aligned}$$

$$P(W = b, Y = b, Z = b | X = b) = \frac{3}{4} \cdot \frac{3}{4} \cdot \frac{2}{5} = \frac{9}{40} = 0.225$$

c) Expresión simplificada de $P(X | W, Y, Z)$:

$$\begin{aligned}
 P(X | W, Y, Z) &= \frac{P(W, X, Y, Z)}{P(W, Y, Z)} = \frac{P(X) P(Y | X) P(Z | X) \cancel{P(W | Y, Z)}}{\sum_{x \in \{a, b\}} P(X = x) P(Y | X = x) P(Z | X = x) \cancel{P(W | Y, Z)}} \\
 &= \frac{\cancel{(1/2)} P(Y | X) P(Z | X)}{\cancel{(1/2)} \sum_{x \in \{a, b\}} P(Y | X = x) P(Z | X = x)} = \frac{P(Y | X) P(Z | X)}{\sum_{x \in \{a, b\}} P(Y | X = x) P(Z | X = x)}
 \end{aligned}$$

$$P(X = b | W = b, Y = b, Z = b) = \frac{P(Y = b | X = b) P(Z = b | X = b)}{\sum_{x \in \{a, b\}} P(Y = b | X = x) P(Z = b | X = x)} = \frac{3/4 \cdot 3/4}{3/4 \cdot 3/4 + 2/3 \cdot 2/3} = 0.5586$$