

Examen de Aprendizaje Automático  
ETSINF, Universitat Politècnica de València, 10 de enero de 2018

Apellidos:  Nombre:  Grupo:

**Cuestiones (2 puntos; tiempo estimado: 30 minutos)**

Marca cada recuadro con una única opción de entre las dadas. Cada acierto suma 1/2 puntos y cada fallo resta 1/6 puntos.

- 1 ☐ C Sea  $S$  un conjunto de 1000 datos supervisados o etiquetados. Para el diseño de un sistema de reconocimiento de formas, se utilizan datos de  $S$  tanto para aprender los parámetros del modelo de reconocimiento,  $\mathcal{M}$ , como para estimar el error de reconocimiento dicho modelo. Para ello se ha utilizado el método de *validación cruzada en 10 bloques*, obteniéndose 4, 0, 4, 3, 4, 0, 3, 5, 4, 3 errores. Indicar cual de las siguientes afirmaciones es *correcta*.
- A) El test efectivo es de 100 muestras, el conjunto de entrenamiento efectivo es de 900 muestras, el error empírico  $\hat{p}$  es del 3 % y el intervalo de confianza es de  $3.0 \pm 0.1$  %
- B) El test efectivo es de 1000 muestras, el conjunto de entrenamiento efectivo es de 1000 muestras, el error empírico  $\hat{p}$  es del 3 % y el intervalo de confianza es de  $3 \pm 1$  %
- C) El test efectivo es de 1000 muestras, el conjunto de entrenamiento efectivo es de 900 muestras, el error empírico  $\hat{p}$  es del 3 % y el intervalo de confianza es de  $3 \pm 1$  %
- D) El test efectivo es de 1000 muestras, el conjunto de entrenamiento efectivo es de 900 muestras, el error empírico  $\hat{p}$  es del 6 % y el intervalo de confianza es de  $6 \pm 1$  %
- 2 ☐ A Sea  $S = \{(\mathbf{x}_1, c_1), \dots, (\mathbf{x}_N, c_N)\}$ ,  $\mathbf{x}_n \in \mathbb{R}^D$ ,  $c_n \in \{+1, -1\}$  una muestra de entrenamiento. El algoritmo perceptrón muestra a muestra ("online") trata de encontrar una solución  $\hat{\boldsymbol{\theta}}$  que satisfaga el sistema de  $N$  inecuaciones. Si queremos una solución con *margen*, esto es encontrar una solución  $\hat{\boldsymbol{\theta}}$  que satisfaga el sistema de  $N$  inecuaciones:  $c_n \boldsymbol{\theta}^t \mathbf{x}_n \geq b$ ,  $1 \leq n \leq N$ , para  $b \in \mathbb{R}^{\geq 0}$ . Indicar cuál de los siguientes algoritmos implementa la solución con margen, partiendo de que  $\boldsymbol{\theta}(1) = \text{arbitrario}$ :
- A)  $\boldsymbol{\theta}(k+1) = \begin{cases} \boldsymbol{\theta}(k) & c(k) \boldsymbol{\theta}^t \mathbf{x}(k) \geq b \\ \boldsymbol{\theta}(k) + \rho_k c(k) \mathbf{x}(k) & c(k) \boldsymbol{\theta}^t \mathbf{x}(k) < b \end{cases}$
- B)  $\boldsymbol{\theta}(k+1) = \begin{cases} \boldsymbol{\theta}(k) & c(k) \boldsymbol{\theta}^t \mathbf{x}(k) < b \\ \boldsymbol{\theta}(k) + \rho_k c(k) \mathbf{x}(k) & c(k) \boldsymbol{\theta}^t \mathbf{x}(k) \geq b \end{cases}$
- C)  $\boldsymbol{\theta}(k+1) = \begin{cases} b \boldsymbol{\theta}(k) & c(k) \boldsymbol{\theta}^t \mathbf{x}(k) \geq 0 \\ b \boldsymbol{\theta}(k) + \rho_k c(k) \mathbf{x}(k) & c(k) \boldsymbol{\theta}^t \mathbf{x}(k) < 0 \end{cases}$
- D)  $\boldsymbol{\theta}(k+1) = \begin{cases} \boldsymbol{\theta}(k) & c(k) \boldsymbol{\theta}^t \mathbf{x}(k) \geq b \\ \boldsymbol{\theta}(k) + \rho_k b c(k) \mathbf{x}(k) & c(k) \boldsymbol{\theta}^t \mathbf{x}(k) < b \end{cases}$
- 3 ☐ A Las siguientes afirmaciones se refieren al método Esperanza Maximización (EM) aplicado a una muestra de entrenamiento  $S$ . Identificar cuál de ellas es *correcta*:
- A) EM es útil para estimar valores máximo-verosímiles de los parámetros de modelos estadísticos a partir de  $S$  cuando hay variables latentes o ocultos.
- B) EM no se puede aplicar en la estimación de valores máximo-verosímiles de los parámetros de modelos estadísticos a partir de  $S$  cuando no hay variables latentes o ocultas.
- C) La rapidez de convergencia de EM puede mejorarse eligiendo un factor de aprendizaje adecuado para  $S$ .
- D) La rapidez de convergencia de EM siempre puede mejorarse inicializando los parámetros a cero.
- 4 ☐ D En la red bayesiana cuya distribución conjunta es  $P(x_1, x_2, x_3, x_4) = P(x_1) P(x_2 | x_1) P(x_3 | x_1) P(x_4 | x_2, x_3)$  ¿cuál de las relaciones siguientes es *falsa* en general?
- A)  $P(x_1, x_4 | x_3) = P(x_1 | x_3) P(x_4 | x_3)$
- B)  $P(x_2, x_3 | x_1) = P(x_2 | x_1) P(x_3 | x_1)$
- C)  $P(x_2, x_3) = P(x_2) P(x_3)$
- D)  $P(x_2, x_3 | x_4) = P(x_2 | x_4) P(x_3 | x_4)$

## Problema 1 (3 puntos; tiempo estimado: 30 minutos)

Para el aprendizaje de una máquina de vectores soporte se dispone de la siguiente muestra de entrenamiento linealmente separable:

$$S = \{((6, 6), -1), ((6, 2), -1), ((1, 6), +1), ((2, 2), +1), ((2, 3), +1), ((4, 2), -1), ((3, 5), -1), ((3, 4), -1), ((1, 2), +1), ((2, 1), +1)\}$$

Los multiplicadores de Lagrange óptimos son:  $\alpha^* = (0.0, 0.0, 0.25, 0.0, 1.0, 0.0, 0.0, 1.25, 0.0, 0.0)^t$ .

- Obtener la función discriminante lineal correspondiente
- Obtener la ecuación de la frontera de decisión entre clases y representar gráficamente los puntos de entrenamiento y dicha frontera.
- Calcular el margen óptimo
- Clasificar la muestra  $(3, 1)$ .

a) Función discriminante lineal (FDL):

- Vector de pesos:

$$\theta_1^* = +1 \cdot 0.25 \cdot 1 + 1 \cdot 1.0 \cdot 2 - 1 \cdot 1.25 \cdot 3 = -1.5$$


$$\theta_2^* = +1 \cdot 0.25 \cdot 6 + 1 \cdot 1.0 \cdot 3 - 1 \cdot 1.25 \cdot 4 = -0.5$$

- Peso umbral (con el tercer vector de entrenamiento):  $\theta_0^* = (+1) - (-1.5 \cdot 1 - 0.5 \cdot 6) = 5.5$
- FDL:  $\phi(\mathbf{x}) = -1.5 x_1 - 0.5 x_2 + 5.5$

b) Ecuación de la frontera de decisión:

$$-1.5 x_1 - 0.5 x_2 + 5.5 = 0 \Rightarrow x_2 = -3x_1 + 11$$

Representación gráfica:



c) Margen óptimo:

$$\frac{2}{\|\theta^*\|} = \frac{2}{\sqrt{(-1.5)^2 + (-0.5)^2}} = 1.265$$


Alternativamente:

$$2 \left( \sum_{n \in \mathcal{V}} \alpha_n^* \right)^{-1/2} = \frac{2}{\sqrt{0.25 + 1.0 + 1.25}} = 1.265$$

d) Clasificación de la muestra  $(3, 1)$ :  $\phi(3, 1) = -1.5 \cdot 3 - 0.5 \cdot 1 + 5.5 = 0.5 > 0 \Rightarrow \text{clase} = +1$

## Problema 2 (3 puntos; tiempo estimado: 30 minutos)

La red hacia adelante (“feedforward”) de la figura se utiliza para resolver un problema de regresión, con función de activación de los nodos de la capa de salida y de la capa oculta de tipo *sigmoid*, y factor de aprendizaje  $\rho = 1.0$ .



Dados los pesos iniciales indicados en la figura, un vector de entrada  $\mathbf{x}^t = (1, 1)$  y su valor deseado de salida  $t = (0.1, 0.9)$ , Calcular:

- las salidas de todas las unidades
- los correspondientes errores en los nodos de la capa de salida y en los de la capa oculta.
- Los nuevos valores de los pesos de las conexiones al nodo 2 de la capa oculta.

- Las salidas de todas las unidades

Capa oculta

$$\phi_1^1 = \theta_{10}^1 + \theta_{11}^1 x_1 + \theta_{12}^1 x_2 = 3$$

$$s_1^1 = \frac{1}{1 + \exp(-\phi_1^1)} = 0.953$$

$$\phi_2^1 = \theta_{20}^1 + \theta_{21}^1 x_1 + \theta_{22}^1 x_2 = -1$$

$$s_2^1 = \frac{1}{1 + \exp(-\phi_2^1)} = 0.269$$

Capa de salida

$$\phi_1^2 = \theta_{10}^2 + \theta_{11}^2 s_1^1 + \theta_{12}^2 s_2^1 = 2.221$$

$$s_1^2 = \frac{1}{1 + \exp(-\phi_1^2)} = 0.902$$

$$\phi_2^2 = \theta_{20}^2 + \theta_{21}^2 s_1^1 + \theta_{22}^2 s_2^1 = -0.222$$

$$s_2^2 = \frac{1}{1 + \exp(-\phi_2^2)} = 0.445$$

- Los errores en la capa de salida son:

$$\delta_1^2 = (t_1 - s_1^2) s_1^2 (1 - s_1^2) = -0.0708 \quad \delta_2^2 = (t_2 - s_2^2) s_2^2 (1 - s_2^2) = +0.1124$$

Los errores en la capa de oculta son:

$$\delta_1^1 = (\delta_1^2 \theta_{11}^2 + \delta_2^2 \theta_{21}^2) s_1^1 (1 - s_1^1) = -0.0082 \quad \delta_2^1 = (\delta_1^2 \theta_{12}^2 + \delta_2^2 \theta_{22}^2) s_2^1 (1 - s_2^1) = -0.0360$$

- Los nuevos pesos del nodo 2 son:

$$\theta_{20}^1 = \theta_{20}^1 + \rho \delta_2^1 (+1) = 0.964$$

$$\theta_{21}^1 = \theta_{21}^1 + \rho \delta_2^1 x_1 = -1.036$$

$$\theta_{22}^1 = \theta_{22}^1 + \rho \delta_2^1 x_2 = -1.036$$

### Problema 3 (2 puntos; tiempo estimado: 20 minutos)

Considerar la red bayesiana  $\mathcal{R}$  definida como  $P(W, X, Y, Z) = P(W) P(X | W) P(Y | W) P(Z | X)$ , cuyas variables aleatorias,  $W, X, Y, Z$ , toman valores en el conjunto  $\{a, b, c\}$ . Las distribuciones de probabilidad asociadas son como sigue:

- $P(W)$  es uniforme:  $P(W = a) = P(W = b) = P(W = c)$ ,
- $P(X | W)$ ,  $P(Y | W)$  y  $P(Z | X)$  vienen dadas en las siguientes tablas:


| $P(x   w)$ | $x:$ | a   | b   | c   |
|------------|------|-----|-----|-----|
| $w: a$     |      | 1/2 | 0   | 1/2 |
| $b$        |      | 1/4 | 1/2 | 1/4 |
| $c$        |      | 1/5 | 3/5 | 1/5 |

| $P(y   w)$ | $y:$ | a   | b   | c   |
|------------|------|-----|-----|-----|
| $w: a$     |      | 1/3 | 0   | 2/3 |
| $b$        |      | 1/4 | 1/2 | 1/4 |
| $c$        |      | 0   | 3/5 | 2/5 |

| $P(z   x)$ | $z:$ | a   | b   | c   |
|------------|------|-----|-----|-----|
| $x: a$     |      | 1/3 | 0   | 2/3 |
| $b$        |      | 1/4 | 1/2 | 1/4 |
| $c$        |      | 0   | 3/5 | 2/5 |

- Representar gráficamente la red
- Obtener una expresión simplificada de  $P(X, Y, Z | W)$  en función de las distribuciones que definen  $\mathcal{R}$  y calcular  $P(X = b, Y = b, Z = b | W = c)$
- Obtener una expresión simplificada de  $P(W | X, Y, Z)$ , y calcular  $P(W = c | X = b, Y = b, Z = b)$

- Representación gráfica de la red:



- Expresión simplificada de  $P(X, Y, Z | W)$ :

$$\begin{aligned}
 P(X, Y, Z | W) &= \frac{P(W, X, Y, Z)}{P(W)} = \frac{\cancel{P(W)} P(X | W) P(Y | W) P(Z | X)}{\cancel{P(W)}} \\
 &= P(X | W) P(Y | W) P(Z | X)
 \end{aligned}$$

$$P(X = b, Y = b, Z = b | W = c) = \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{1}{2} = \frac{9}{50} = 0.18$$

- Expresión simplificada de  $P(W | X, Y, Z)$ :

$$\begin{aligned}
 P(W | X, Y, Z) &= \frac{P(W, X, Y, Z)}{P(X, Y, Z)} = \frac{P(W) P(X | W) P(Y | W) \cancel{P(Z | X)}}{\sum_{w \in \{a, b, c\}} P(W = w) P(X | W = w) P(Y | W = w) \cancel{P(Z | X)}} \\
 &= \frac{\cancel{(1/3)} P(X | W) P(Y | W)}{\cancel{(1/3)} \sum_{w \in \{a, b, c\}} P(X | W = w) P(Y | W = w)} = \frac{P(X | W) P(Y | W)}{\sum_{w \in \{a, b, c\}} P(X | W = w) P(Y | W = w)}
 \end{aligned}$$

$$\begin{aligned}
 P(W = c | X = b, Y = b, Z = b) &= \frac{P(X = b | W = c) P(Y = b | W = c)}{\sum_{w \in \{a, b, c\}} P(X = b | W = w) P(Y = b | W = w)} \\
 &= \frac{(3/5)^2}{0 + (1/2)^2 + (3/5)^2} = \frac{36}{61} \approx 0.59
 \end{aligned}$$